

SmartBancs

Sistema de Transferencias en Tiempo Real

[MVP Bancario]

[Alta Concurrencia]

[Persistencia Asíncrona]

[IA Integrada]

[Observabilidad Total]

El Reto Arquitectónico: Velocidad vs. Inteligencia



El Mandato del Usuario

[Respuesta casi instantánea (baja latencia)]

[Consistencia absoluta del dinero]

[Disponibilidad inmediata]



El Mandato del Sistema


[Persistencia durable (PostgreSQL)]

[Recomendaciones financieras
(Inteligencia Artificial)]


[Telemetría y auditoría continua]

La arquitectura exige una separación radical: aislar el camino crítico (Hot Path) de los procesos secundarios (Cold Path).

Arquitectura Topológica Orientada a Eventos



Anatomía de una Transferencia (El Flujo Crítico)



Garantías de Consistencia, Idempotencia y ACID

Atomicidad & Aislamiento (El Motor)

Redis Lua. Motor monohilo
Validación y actualización de saldo ocurren como una unidad indivisible sin condiciones de carrera ni bloqueos de base de datos.



Idempotencia (El Escudo)

`clave_idempotencia`
Protección estricta frente a reintentos de red del cliente. Imposible duplicar un cargo por timeouts o doble clic.



Durabilidad (El Archivo)

PostgreSQL + Batches
Almacenamiento definitivo a largo plazo operando en el Cold Path mediante inserciones optimizadas por lotes de 100 registros.




Tolerancia a Fallos (El Aislamiento)

DLQ (Dead Letter Queue)
Eventos corruptos se aíslan automáticamente para revisión sin detener la cola principal de procesamiento.



Workers y Procesamiento Asíncrono Desacoplado



worker-publicador

Misión: Extraer de Redis Stream y publicar en tópicos MQTT.
Puente resiliente entre la memoria rápida y el bus principal.

worker-persistencia

Misión: Consumir de MQTT y guardar en PostgreSQL. Utiliza inserción por lotes. Si la BD se ralentiza, la API principal sigue intacta.

worker-ia

Misión: Consumir de MQTT para análisis paralelo. Escalabilidad horizontal a demanda completamente aislada del dominio transaccional.

Inteligencia Artificial: El Copiloto Silencioso

Ingreso de Datos (Inputs)



Evento de transferencia
(vía MQTT) combinado con
datos financieros
pre-procesados mediante
pipeline ETL.

Motor de Reglas (Procesamiento Seguro)



Evaluación 100% interna. Sin
fuga de datos a redes externas.
Clasificación simultánea de
capacidad financiera e
impacto de liquidez.

Notificación en Vivo (Outputs)



Persistencia asíncrona de
la recomendación y emisión
silenciosa hacia el cliente
mediante WebSocket en la UI.

La transferencia sucede en milisegundos; la recomendación llega un instante después, enriqueciendo la experiencia sin bloquearla.


Telemetría, Observabilidad y Operación



Métricas (VictoriaMetrics)

Almacenamiento eficiente de series de tiempo.

Golden Signals:
TPS, Latencia HTTP,
Latencia de Lua,
Eventos MQTT,
Tamaño de DLQ.



Logs Estructurados (Loki)

Centralización de logs de contenedores vía Alloy.

Visibilidad inmediata de errores, timeouts y estados de transacción por worker.



El Hilo de Ariadna (trace_id)

Un identificador único viaja desde FastAPI -> Redis -> MQTT -> Postgres -> IA.

Permite la reconstrucción quirúrgica de cualquier transacción distribuida en un solo panel.


Pruebas de Carga: Sometiendo el Sistema al Límite

Requisito: Latencia máxima 2,000 ms
Entorno: k6 + 4 workers Uvicorn + 4 cores



59,933 transacciones procesadas en 30 segundos

Latencia p95: **201.42 ms**



Tasa de Error HTTP: **0.00%**

Integridad de Negocio: **100%**

Resiliencia comprobada. A 2000 TPS, la arquitectura ni siquiera suda.

Conclusiones del MVP y Ruta de Escalamiento Empresarial

EL MVP Funciona



Arquitectura puramente orientada a eventos.



Transacciones ACID en memoria sin deadlocks.



IA desacoplada sin penalizar al usuario.



Telemetría y diagnóstico extremo a extremo.

El Futuro Inmediato



Escalamiento API: Múltiples réplicas de api-transacciones detrás de un Load Balancer.



Grupos de Consumidores: Aumento horizontal de workers en Redis y MQTT para absorber picos masivos.



Integración Legada: Un nuevo worker-bancs dedicado para sincronizar saldos asíncronamente con el Core legado, protegiéndolo de la saturación.